

Deney Sonuçları Raporu

Derin Öğrenme — Veri Sayısı Azaltma, Sınıf Dengesizliği ve Genişletilmiş Metrikler

Bu rapor, **Yapılacaklar Belgesi**'nde tarif edilen dört adımın uygulanmasıyla elde edilen sonuçları içerir. Toplam **48 eğitim** yapılmıştır: 20 deney veri sayısı azaltılarak, 12 deney sınıflar dengesizleştirilerek, 16 deney hazır mimarilerle (ResNet18, MobileNetV2). Tüm metrikler **tam ve dengeli 10.000'lik MNIST test setinde** ölçülmüştür — eğitim seti değiştirilmiş, test seti sabit tutulmuştur. Aksi halde azınlık sınıflarının recall'ü ölçülemezdi.

Deney Kurulumu

Ayar	Değer	Gerekçe
Test seti	Tam MNIST test — 10.000, dengeli	Azınlık recall'ü ancak dengeli testte ölçülebilir
Epoch	10 (tüm deneylerde sabit)	Adil karşılaştırma; 5 epoch az veride yetersiz
Batch size / LR / Optimizer	128 / 0.001 / Adam	Eski deneylerle birebir aynı
Seed	27 (tek tekrar)	Tekrar üretilebilirlik
Cihaz	GPU — NVIDIA RTX 4060 Laptop	CUDA 12.4, PyTorch 2.5.1
Azınlık sınıfları	5, 6, 8	Belgede tarif edilen sınıflar
Çoğunluk sınıfları	0, 1	Belgede tarif edilen sınıflar

Karşılaştırılan konfigürasyonlar

Kod	Mimari	Not
MLP_d0	MLP [256, 128], dropout yok	Eski <i>MLP_2_katman</i> deneyi ile aynı
MLP_d03	MLP [256, 128], dropout 0.3	Eski <i>MLP_dropout_0.3</i> deneyi ile aynı
CNN_d0	CNN (16, 32), dropout yok	Eski <i>CNN_dropout_0</i> deneyi ile aynı
CNN_d03	CNN (16, 32), dropout 0.3	Eski <i>CNN_dropout_0.3</i> deneyi ile aynı
ResNet18	torchvision, sıfırdan	28×28 gri → 32×32×3'e uyarlandı
MobileNetV2	torchvision, sıfırdan	28×28 gri → 32×32×3'e uyarlandı

İlk dört konfigürasyon eski deneylerin birebir aynısıdır; bu sayede eski Accuracy değerleriyle doğrudan karşılaştırma yapılabilmektedir.

Dengesizlik profilleri

Profil	Sınıf 0, 1	Sınıf 2,3,4,7,9	Sınıf 5, 6, 8	Toplam	Oran
P1_pdf	3.000	500	150	8.950	20:1
P2_agir	3.000	300	100	7.800	30:1
P3_5k	1.500	300	120	4.860	12.5:1

P1_pdf, belgedeki tarifi birebir uygulanmasıdır (çoğunluk 3.000+, azınlık 100–150). *P3_5k* ise belgedeki "5.000 + dengesiz" satırına toplam boyutça en yakın olandır.

1. Adım — Veri Sayısını Azalt

Sorun: Tam veri setinde (60.000 örnek) tüm modeller ~%98-99 accuracy veriyor — farklı konfigürasyonlar arasındaki fark gözlemlenemiyor.

MLP [256, 128] — dropout yok

Veri Sayısı	Accuracy	F1 (macro)	Recall Azınlık	Loss
60.000 (tam) — eski rapor, CPU, 5 epoch	%97.75	—	—	0.0711
60.000 (tam) — yeni	%97.84	%97.83	%97.88	0.0805
10.000	%95.0	%94.95	%93.05	0.1699
5.000	%93.12	%93.05	%92.31	0.2433
3.000	%91.62	%91.51	%90.98	0.2849
1.000	%89.24	%89.02	%83.25	0.3809

MLP [256, 128] — dropout 0.3

Veri Sayısı	Accuracy	F1 (macro)	Recall Azınlık	Loss
60.000 (tam) — eski rapor, CPU, 5 epoch	%97.66	—	—	0.0728
60.000 (tam) — yeni	%97.95	%97.94	%97.46	0.0676
10.000	%95.4	%95.35	%93.91	0.1456
5.000	%93.6	%93.52	%92.4	0.2117
3.000	%91.88	%91.77	%90.43	0.2681
1.000	%88.75	%88.51	%85.13	0.3923

CNN (16, 32) — dropout yok

Veri Sayısı	Accuracy	F1 (macro)	Recall Azınlık	Loss
60.000 (tam) — eski rapor, CPU, 5 epoch	%98.80	—	—	0.0330
60.000 (tam) — yeni	%98.98	%98.97	%98.81	0.0337
10.000	%97.63	%97.62	%97.37	0.0708
5.000	%96.18	%96.16	%95.83	0.1186
3.000	%94.87	%94.81	%94.35	0.1703
1.000	%87.63	%87.52	%85.69	0.4176

CNN (16, 32) — dropout 0.3

Veri Sayısı	Accuracy	F1 (macro)	Recall Azınlık	Loss
60.000 (tam) — eski rapor, CPU, 5 epoch	%98.85	—	—	0.0344
60.000 (tam) — yeni	%99.12	%99.11	%98.97	0.0271
10.000	%97.74	%97.74	%98.04	0.0681
5.000	%96.06	%96.04	%95.83	0.1201
3.000	%95.34	%95.3	%95.47	0.154
1.000	%88.7	%88.54	%85.93	0.3992

Konfigürasyonlar arası fark — belgenin ana tezi

Veri Sayısı	Acc min	Acc max	Acc farkı	F1 min	F1 max	F1 farkı
60.000 (tam)	%97.84	%99.12	1.28 puan	%97.83	%99.11	1.28 puan
10.000	%95.0	%97.74	2.74 puan	%94.95	%97.74	2.79 puan
5.000	%93.12	%96.18	3.06 puan	%93.05	%96.16	3.11 puan
3.000	%91.62	%95.34	3.72 puan	%91.51	%95.3	3.79 puan
1.000	%87.63	%89.24	1.61 puan	%87.52	%89.02	1.5 puan

Tez doğrulandı, ama bir sınırla. Konfigürasyonlar arası fark tam veride yalnızca **1.28 puan** iken, **3.000** örnekte **3.72 puana** çıkıyor — modeller gerçekten ayrışıyor. Ancak 1.000 örnekte fark tekrar daralıyor, çünkü orada bütün modeller birlikte çöküyor ve ayrışacak performans kalmıyor. **Ayrım için en verimli aralık 3.000–5.000 örnektir.**

Beklenmedik bulgu: CNN'in üstünlüğü veri miktarına bağlı

Veri Sayısı	MLP_d0 Accuracy	CNN_d0 Accuracy	Fark
60.000 (tam)	%97.84	%98.98	CNN +1.14
10.000	%95.0	%97.63	CNN +2.63
5.000	%93.12	%96.18	CNN +3.06
3.000	%91.62	%94.87	CNN +3.25
1.000	%89.24	%87.63	MLP +1.61

1.000 örnekte **MLP, CNN'i geçiyor**. Konvolüsyon katmanlarının öğrenmesi gereken filtreler var; bu kadar az veriyle onları öğrenemiyor ve basit MLP daha iyi genelliyor. Yalnızca tam veri setine bakan biri "CNN her koşulda üstündür" sonucuna varırdı — bu yanlış olurdu.

2. Adım — Sınıfları Dengesiz Hale Getir

Amaç: Bazı sınıflara çok az örnek bırakarak modelin azınlık sınıflarına karşı nasıl davrandığını gözlemlemek. Her tablodaki ilk satır, aynı büyüklükteki *dengeli* veri setinin sonucudur — karşılaştırma referansı.

MLP [256, 128] — dropout yok

Veri Seti	Accuracy	F1 (macro)	Recall Azınlık	Recall Çoğunluk	Acc – AzRec
<i>dengeli 5.000 (referans)</i>	%93.12	%93.05	%92.31	%97.53	—
P1_pdf — 8.950 örnek (20:1)	%91.09	%90.85	%81.1	%99.63	9.99 p
P2_agir — 7.800 örnek (30:1)	%90.44	%90.18	%80.96	%99.2	9.48 p
P3_5k — 4.860 örnek (12.5:1)	%90.98	%90.83	%86.46	%99.14	4.52 p

MLP [256, 128] — dropout 0.3

Veri Seti	Accuracy	F1 (macro)	Recall Azınlık	Recall Çoğunluk	Acc – AzRec
<i>dengeli 5.000 (referans)</i>	%93.6	%93.52	%92.4	%97.47	—
P1_pdf — 8.950 örnek (20:1)	%91.12	%90.81	%80.98	%99.53	10.14 p
P2_agir — 7.800 örnek (30:1)	%90.34	%90.11	%81.04	%99.41	9.3 p
P3_5k — 4.860 örnek (12.5:1)	%90.78	%90.56	%84.5	%99.39	6.28 p

CNN (16, 32) — dropout yok

Veri Seti	Accuracy	F1 (macro)	Recall Azınlık	Recall Çoğunluk	Acc – AzRec
<i>dengeli 5.000 (referans)</i>	%96.18	%96.16	%95.83	%98.98	—
P1_pdf — 8.950 örnek (20:1)	%95.34	%95.27	%91.35	%99.67	3.99 p
P2_agir — 7.800 örnek (30:1)	%92.8	%92.61	%84.4	%99.63	8.4 p
P3_5k — 4.860 örnek (12.5:1)	%93.07	%92.97	%88.51	%99.38	4.56 p

CNN (16, 32) — dropout 0.3

Veri Seti	Accuracy	F1 (macro)	Recall Azınlık	Recall Çoğunluk	Acc – AzRec
<i>dengeli 5.000 (referans)</i>	%96.06	%96.04	%95.83	%99.15	—
P1_pdf — 8.950 örnek (20:1)	%95.0	%94.91	%89.83	%99.63	5.17 p
P2_agir — 7.800 örnek (30:1)	%93.59	%93.48	%87.24	%99.61	6.35 p
P3_5k — 4.860 örnek (12.5:1)	%93.74	%93.66	%91.34	%99.39	2.4 p

Aynı veri bütçesi, sadece denge değişti

Dengeli 10.000 → dengesiz 8.950 (P1_pdf). Veri miktarı neredeyse aynı, değişen tek şey sınıf dağılımı.

Konfigürasyon	Accuracy değişimi	F1 değişimi	Recall Azınlık değişimi	Hasar oranı
MLP_d0	-3.91 p	-4.1 p	-11.95 p	3.1×
MLP_d03	-4.28 p	-4.54 p	-12.93 p	3.0×
CNN_d0	-2.29 p	-2.35 p	-6.02 p	2.6×
CNN_d03	-2.74 p	-2.83 p	-8.21 p	3.0×

Accuracy hasarı 2–3 kat küçük gösteriyor. Accuracy'ye bakan biri "3–4 puan kaybettik, idare eder" der. Gerçekte azınlık sınıflarının recall'ü **12 puana kadar** düşmüştür. Belgenin kanıtlamak istediği tam olarak budur: **Accuracy tek başına yanıltıcıdır.**

3. Adım — Genişletilmiş Metrikler

Precision yüksek, Recall düşük — dengesizliğin imzası

Deney: **CNN_d0_dengesiz_P2_agir** (30:1 dengesizlik). Accuracy %92.80 görünüyor.

Sınıf	Tip	Eğitim örneği	Test örneği	Precision	Recall	F1
0	çoğunluk	3000	980	%85.93	%99.69	%92.3
1	çoğunluk	3000	1135	%95.68	%99.56	%97.58
2	orta	300	1032	%91.51	%95.06	%93.25
3	orta	300	1010	%85.48	%97.92	%91.28
4	orta	300	982	%95.88	%94.91	%95.39
5	AZINLIK	100	892	%97.37	%87.11	%91.95
6	AZINLIK	100	958	%95.48	%92.59	%94.01
7	orta	300	1028	%96.45	%92.51	%94.44
8	AZINLIK	100	974	%97.95	%73.51	%83.99
9	orta	300	1009	%90.65	%93.16	%91.89

Tablodaki asimetri, tek başına accuracy'nin neden yetersiz olduğunun en net kanıtıdır:

- Sınıf 8 (azınlık, 100 eğitim örneği):** Precision %97.95 — model "8" dediğinde neredeyse hep haklı. Ama Recall %73.51 — gerçek 8'lerin dörtte birini kaçırıyor. Model "8" demeye çekiniyor.
- Sınıf 0 (çoğunluk, 3.000 eğitim örneği):** Tam tersi. Recall %99.69 — hiç kaçırmıyor. Ama Precision %85.93 — "0" dediklerinin %14'ü aslında başka sınıf. Diğer sınıfları yutuyor.

Bu asimetri Accuracy'de görünmez. F1'de de görünmez, çünkü precision ve recall birbirini ortalayıp sınıf 8 için %83.99 gibi makul bir sayı üretir. Yalnızca ikisine **ayrı ayrı** bakıldığında ortaya çıkar.

Confusion Matrix — hatanın nereye gittiği

Precision/Recall/F1 hatanın **ne kadar** olduğunu söyler. Confusion Matrix hatanın **nereye** gittiğini söyler — ve teşhis oradadır. Bir azınlık sınıfının görsel olarak benzer bir rakama kayması ile çoğunluk sınıfına kayması tamamen farklı iki sorundur ve farklı çözümler gerektirir; recall değeri ikisinde de aynı çıkar.

CNN_d0 — 60.000 örnek (tam veri, dengeli)

Accuracy %98.98 — köşegen dışı neredeyse boş. Bu tabloda ayırt edici bilgi yok.

gerçek \ tahmin	0	1	2	3	4	5	6	7	8	9
0	974	.	.	1	.	.	3	.	2	.
1	.	1124	2	.	.	.	3	.	6	.
2	1	.	1023	1	1	.	.	3	3	.
3	.	.	2	999	.	1	.	.	6	2
4	.	.	.	.	973	.	1	.	1	7
5	2	.	.	9	.	874	3	.	2	2
6	2	1	.	.	1	1	951	.	2	.
7	.	1	7	.	.	.	.	1014	1	5
8	2	.	2	.	.	.	.	1	966	3
9	.	.	.	1	2	.	1	2	3	1000

CNN_d0 — 1.000 örnek (dengeli)

Accuracy %87.63 — hatalar tüm sınıflara dağılmış, belirli bir yapı yok. Sorun veri yetersizliği.

gerçek \ tahmin	0	1	2	3	4	5	6	7	8	9
0	969	.	1	1	.	3	3	2	1	.
1	.	1069	17	1	1	7	8	1	31	.
2	36	2	895	13	14	1	19	21	27	4
3	24	3	32	821	.	51	5	39	25	10
4	2	.	5	.	755	1	20	5	2	192
5	31	1	8	25	10	763	17	10	17	10
6	40	5	7	.	9	16	877	.	4	.
7	2	6	29	2	3	.	.	934	4	48
8	37	3	15	12	9	33	8	30	779	48
9	21	4	3	6	7	7	.	57	3	901

CNN_d0 — 7.800 örnek, dengesiz (P2_agir)

Accuracy %92.80 — hatalar artık rastgele değil: azınlık satırları (kırmızı) belirli sütunlara yığılıyor.

gerçek \ tahmin	0	1	2	3	4	5	6	7	8	9
0	977	.	.	1	.	1	.	1	.	.
1	.	1130	2	.	.	.	2	.	1	.
2	12	7	981	14	2	.	6	8	2	.
3	5	.	4	989	.	.	.	7	3	2
4	3	3	11	1	932	.	8	1	2	21
5	26	6	2	48	2	777	14	1	6	10
6	49	4	4	.	5	9	887	.	.	.
7	4	7	28	11	6	.	.	951	.	21
8	45	15	37	76	10	11	12	9	716	43
9	16	9	3	17	15	.	.	8	1	940

Azınlık sınıfları nereye kaçıyor?

Deney: CNN_d0_dengesiz_P2_agir

- Sınıf 5: 892 test örneğinin 115'i yanlış sınıfa gidiyor → '3' (48), '0' (26), '6' (14)
- Sınıf 6: 958 test örneğinin 71'i yanlış sınıfa gidiyor → '0' (49), '5' (9), '4' (5)
- Sınıf 8: 974 test örneğinin 258'i yanlış sınıfa gidiyor → '3' (76), '0' (45), '9' (43)

İki farklı mekanizma iç içe çalışıyor:

- **Görsel benzerlik:** 8 → '3', 5 → '3'. Bu sınıflar zaten birbirine benzer; az veriyle ayırım kayboluyor. Çözüm: daha iyi özellik çıkarımı, augmentation, daha derin model.
- **Çoğunluk çekimi:** 6 → '0', 5 → '0'. 6 ile 0 görsel olarak benzemez. Model görüntüye bakmayı bırakıp **sınıf önceliğini** kullanıyor: "şüphedeysem çoğunluk sınıfını söyle, istatistiksel olarak kârlıyım." Çözüm: class weights, oversampling, focal loss.

Bu ayırım yalnızca Confusion Matrix ile görünür. Recall değeri her iki durumda da aynıdır.

4. Adım — Eski Sonuçlarla ve Modeller Arası Karşılaştırma

Hazır mimariler

ResNet18 — torchvision, sıfırdan eğitim, 32×32×3 girdi

Veri Seti	Accuracy	F1 (macro)	Recall Azınlık	Süre
60.000 (tam)	%98.91	%98.9	%99.05	189.23 sn
10.000	%98.41	%98.4	%97.78	47.11 sn
5.000	%97.77	%97.76	%99.23	36.32 sn
3.000	%96.15	%96.08	%95.78	27.43 sn
1.000	%94.86	%94.81	%94.72	23.02 sn
P1_pdf — 8.950 örnek (20:1)	%96.55	%96.49	%92.15	44.27 sn
P2_agir — 7.800 örnek (30:1)	%94.37	%94.29	%88.79	40.87 sn
P3_5k — 4.860 örnek (12.5:1)	%94.85	%94.84	%91.01	34.6 sn

MobileNetV2 — torchvision, sıfırdan eğitim, 32×32×3 girdi

Veri Seti	Accuracy	F1 (macro)	Recall Azınlık	Süre
60.000 (tam)	%98.86	%98.85	%98.64	236.55 sn
10.000	%96.4	%96.37	%96.36	59.45 sn
5.000	%93.37	%93.31	%91.77	41.18 sn
3.000	%88.9	%88.81	%89.66	33.51 sn
1.000	%52.4	%51.74	%43.37	27.81 sn
P1_pdf — 8.950 örnek (20:1)	%90.38	%90.15	%83.1	54.55 sn
P2_agir — 7.800 örnek (30:1)	%88.68	%88.57	%80.02	50.42 sn
P3_5k — 4.860 örnek (12.5:1)	%86.44	%86.15	%77.61	39.79 sn

ResNet18 az veride çarpıcı biçimde üstün. 1.000 örnekte %94.86 accuracy — aynı veriyle basit CNN %87.63, MLP %89.24 alıyor. Residual bağlantılar ve BatchNorm az veride çok daha iyi genelliyor. Buna karşılık **MobileNetV2 1.000 örnekte çöküyor** (%52.40): depthwise separable konvolüsyonlar ve yoğun BatchNorm katmanları yeterli istatistik bulamıyor.

Dikkat çekici: Tam veri setinde basit CNN_d03 (%99.12) ResNet18'i (%98.91) **geçiyor**. MNIST için ResNet18 gereğinden büyük bir modeldir — 11 milyon parametre, 30 bin parametrelilik bir CNN'in çözdüğü problem için. Model büyüklüğü tek başına üstünlük getirmiyor.

Tüm modeller — tek tabloda

Model	60.000	10.000	5.000	1.000	Azınlık Recall (P1_pdf)
MLP_d0	%97.84	%95.0	%93.12	%89.24	%81.1
MLP_d03	%97.95	%95.4	%93.6	%88.75	%80.98
CNN_d0	%98.98	%97.63	%96.18	%87.63	%91.35
CNN_d03	%99.12	%97.74	%96.06	%88.7	%89.83
ResNet18	%98.91	%98.41	%97.77	%94.86	%92.15
MobileNetV2	%98.86	%96.4	%93.37	%52.4	%83.1

Eski Deneylerle Karşılaştırma

Karşılaştırma iki önceki rapora dayanmaktadır: **MLP_Deney_Sonuclari.pdf** ve **MNIST_CNN_Deney_Sonuclari.pdf** (her ikisi de 15 deney, **CPU, 5 epoch**, yalnızca tam 60.000'lik veri seti). O raporlarda ölçülen metrikler **Accuracy, Loss ve eğitim süresi** ile sınırlıydı — F1, Precision, Recall ve Confusion Matrix yoktu. Yeni deneyler GPU'da ve 10 epoch ile yapılmıştır; bu nedenle sayılar birebir değil, **yön ve büyüklük** olarak karşılaştırılmalıdır.

Aynı konfigürasyon, tam veri seti

Konfigürasyon	Eski (CPU, 5 ep)	Yeni (GPU, 10 ep)	Fark	Eski kaynak
MLP [256, 128] — dropout yok	%97.75	%97.84	0.09 p	MLP raporu — 4 koşunun ortalaması (%97.57 – %97.86)
MLP [256, 128] — dropout 0.3	%97.66	%97.95	0.29 p	MLP raporu — tek koşu
CNN (16, 32) — dropout yok	%98.80	%98.98	0.18 p	CNN raporu — dropout tablosu, (16,32)
CNN (16, 32) — dropout 0.3	%98.85	%99.12	0.27 p	CNN raporu — aynı konfig ikinci koşuda %99.10 vermişti

Farklar 0.3 puanın altında ve hepsi pozitif yönde — beklenen sonuç, çünkü yeni deneyler iki kat epoch görüyor. Kurulumun eski deneylerle tutarlı olduğu doğrulanmıştır.

Koşu varyansı gözlemi. Eski CNN raporunda (16,32) + dropout 0.3 konfigürasyonu iki ayrı yerde raporlanmış ve iki farklı sonuç vermiş: %98.85 ve %99.10. Aynı konfigürasyon, 0.25 puan fark. Bu, tam veri setinde ölçülen küçük farkların (0.1–0.3 puan) **gerçek bir üstünlüğü değil, rastgele koşu varyansını** yansıtabileceğini gösterir — belgenin "farklar gözlemlenemiyor" tespitini destekleyen bağımsız bir kanıttır.

Eski raporların çıkarımları bugün de geçerli mi?

Eski rapordaki çıkarım	Yeni deneylerin sonucu
CNN, MLP'den ~%1–1.2 daha yüksek accuracy verir (CNN raporu, bölüm 6)	Yalnızca yeterli veri varken doğru. 60.000'de CNN +1.14 puan, 5.000'de +3.06 puan, ancak 1.000 örnekte MLP CNN'i 1.61 puan geçiyor.
Tüm CNN deneylerinde accuracy %98'in üzerinde kaldı (CNN raporu, genel sonuç)	Tam veri için doğru. 5.000 örnekte %96.18'e, 1.000 örnekte %87.63'e iniyor.
Dropout 0.1–0.3 en iyi dengeyi sağlar, 0.5 modeli zayıflatır (her iki rapor)	Doğrulandı ve genişletildi: dropout 0.3'ün faydası tam veride 0.14 puanla gürültü seviyesindeyken, 3.000 örnekte 0.47 puana, dengesiz veride azınlık recall'ünde 2.8 puana çıkıyor.
MNIST için 2 conv katman / 2–4 gizli katman yeterli (her iki rapor)	Çalışmıyor. Ek olarak: 1.000 örnekte ResNet18 (%94.86) basit CNN'i (%87.63) 7 puan geçiyor — az veride mimari seçimi çok daha belirleyici.
Ölçülen metrikler: Accuracy, Loss, süre	Yetersiz olduğu ölçüldü. Dengesiz veride accuracy %92.80 iken azınlık sınıfı 8'in recall'ü %73.51. Eski metrik setiyle bu görülemezdi.

CPU → GPU: süre karşılaştırması

Eski deneyler CPU'da 5 epoch, yeni deneyler GPU'da 10 epoch koştuğu için epoch başına süreye normalize edilmiştir. Her iki ölçümde de her epoch sonunda tam test seti değerlendirilmesi yapılmaktadır.

Model	Eski epoch	Eski toplam	Eski sn/epoch	Yeni epoch	Yeni toplam	Yeni sn/epoch	Hızlanma
MLP [256, 128]	5	~21–25 sn	~4.2–5.0 sn	10	46.56 sn	4.66 sn	$\approx 1.0\times$
CNN (16, 32)	5	52 sn	10.4 sn	10	56.54 sn	5.65 sn	$1.8\times$
CNN (32, 64)	5	84 sn	16.8 sn	—	—	—	—

GPU her modelde hızlandırmıyor. MLP'de kazanç neredeyse sıfır ($\approx 1.0\times$) — model o kadar küçük ki darboğaz hesaplama değil, veri yükleme ve çekirdek başlatma gecikmesi. CNN'de ise GPU $1.8\times$ hızlandırıyor, çünkü konvolüsyon işlemi paralelleştirmeye çok daha uygun. **Model küçüldükçe GPU'nun avantajı kayboluyor.**

Genel Çıkarımlar

1. **Veri azaltma işe yarıyor.** Konfigürasyonlar arası fark tam veride 1.28 puan, 3.000 örnekte 3.72 puan. Deneylerin ayırt edici olması için **3.000–5.000 örnek** aralığı önerilir.
2. **Accuracy dengesiz veride yanıltıcıdır — ölçüldü.** Aynı veri bütçesinde dengeden dengesizliğe geçildiğinde accuracy 2–4 puan düşerken azınlık recall'ü 6–13 puan düşüyor. En kötü durum: **MobileNetV2_dengesiz_P3_5k** — accuracy %86.44, azınlık recall **%77.61** (8.83 puan uçurum).
3. **F1 tek başına da yeterli değil.** Precision ve recall zıt yönlerde saptığında F1 ikisini ortalayıp sorunu gizliyor (sınıf 8: precision %97.95, recall %73.51, F1 %83.99). Dengesiz veride **precision ve recall ayrı ayrı** raporlanmalıdır.
4. **Confusion Matrix vazgeçilmez.** Azınlık sınıflarının görsel benzerlik yüzünden mi yoksa çoğunluk çekimi yüzünden mi kaybedildiği yalnızca matriste görünür — ve bu iki sorunun çözümü tamamen farklıdır.
5. **Model seçimi veri miktarına bağlıdır.** 60.000 örnekte sıralama CNN_d03 > ResNet18 > MobileNetV2 > MLP iken, 1.000 örnekte ResNet18 > MLP > CNN > MobileNetV2'ye dönüyor. Tek bir veri boyutunda yapılan karşılaştırma yanıltıcıdır.
6. **CNN dengesizliğe MLP'den dayanıklı.** P1_pdf profilinde azınlık recall CNN_d0'da %91.35, MLP_d0'da %81.1 — dengeli veride aralarındaki fark 2–3 puanken burada 10 puana çıkıyor.

Belgedeki örnek tabloyla fark. Yapılacaklar Belgesi'ndeki örnek senaryo azınlık recall'ünü %38 olarak gösteriyordu; ölçülen en düşük değer %77.61. Bunun nedeni o tablonun *simüle edilmiş* olması ve MNIST'in kolay bir veri seti olmasıdır — 100–150 örnek bir rakamı öğrenmeye büyük ölçüde yetiyor. Etki gerçek ve tutarlı biçimde ölçülmüştür, ancak çöküş seviyesinde değildir. Daha keskin bir tablo için azınlık sınıflarını 20–30 örneğe indiren bir profil eklenmelidir.

Bu rapor `egitim_f1_veri_azalt.py`, `egitim_f1_dengesiz.py` ve `egitim_f1_hazir_modeller.py` tarafından üretilen sonuç dosyalarından (`sonuclar_f1_*.csv`, `sınıf_bazli_*.csv`, 48 adet confusion matrisi) otomatik olarak oluşturulmuştur. Yeni deneylere ait hiçbir sayı elle girilmemiştir. Eski deney değerleri `MLP_Deney_SonucLari.pdf` ve `MNIST_CNN_Deney_SonucLari.pdf` raporlarından alınmıştır.