

Deney Sonuçları Raporu

Görev 5 — PASCAL VOC 2012'de Nesne Tespiti ve Semantik Bölütleme

Bu rapor iki ayrı görme problemini aynı veri seti üzerinde ele alır: **nesne tespiti** (Faster R-CNN) ve **semantik bölütleme** (DeepLabV3). Toplam **14 eğitim** yapılmıştır — tespitte 6, bölütlemede 8. Toplam süre **201,0 dakika** (RTX 4060 Laptop GPU).

Her iki problemde de baseline'dan başlanıp adım adım skor yükseltilmiştir: tespitte **%51,48 → %77,74 mAP@0,5 (+26,26 puan)**, bölütlemede **%56,41 → %64,78 mIoU (+8,37 puan)**.

Ancak bu çalışmanın asıl sonucu skor artışı değil: **her iki problemde de hiç eğitilmemiş hazır model, eğitilen en iyi modelden daha yüksek skor almıştır** (tespitte 3,26 puan, bölütlemede 10,68 puan farkla). Bu beklenen bir sonuç değildi ve raporun merkezinde bu bulgu vardır.

Veri Seti ve Deney Kurulumu

PASCAL VOC 2012 (Kaggle: gopalbhattra/pascal-voc-2012-dataset) — 17.125 JPEG görüntü, 20 nesne kategorisi. Aynı veri setinin iki farklı etiket katmanı var ve Görev 5 ikisini de kullanıyor:

Problem	Etiket kaynağı	Etiketli görüntü	Ne öğreniliyor
Nesne tespiti	Annotations/*.xml	train 5.717 / val 5.823	nesnenin sınıfı + sınırlayıcı kutusu
Semantik bölütleme	SegmentationClass/*.png	train 1.464 / val 1.449	her pikselin sınıfı

Bölütleme etiketleri tespitin alt kümesidir — aynı görüntünün hem kutusu hem maskesi olabilir, ama maskeli görüntü sayısı yaklaşık dörtte bir. Bu fark bölütleme tarafının neden daha zorlandığını kısmen açıklar.

Test seti neden resmi test setinden alınmadı. VOC 2012'nin resmi test setinin etiketleri yayınlanmaz; skor ancak VOC değerlendirme sunucusuna gönderilerek alınır. Elimizdeki etiketli iki küme train ve val. Görev 3 ve 4'teki düzeni korumak için resmi val listesi seed 27 ile ikiye bölünmüştür: **val** (iyileştirme kararları buna bakılarak verilir) ve **test** (her konfigürasyon için yalnızca bir kez ölçülür). Böylece test set leakage olmadan "karar seti / rapor seti" ayrımı korunur.

Karşılaşılan tuzak: arşivde iki VOC klasörü var. Kaggle arşivi VOC2012_train_val/ yanında VOC2012_test/ de içerir ve ikincisinin de Annotations/ + JPEGImages/ klasörleri vardır — ama etiketleri boştur. Alfabetik sırada "test" önce geldiği için basit bir klasör araması **önce onu bulur ve tüm küme listeleri sessizce boş döner**. Çözüm, klasörü tanırken SegmentationClass/ varlığını da şart koşturmak oldu.

Kullanılan alt kümeler

Problem	Train	Val (karar)	Test (rapor)	Epoch sonu takip
Tespit	2.000	500	1.000	val'in 500'ü
Bölütleme	1.464 (tamamı)	724	725	300

Tespitte 2.000'lik alt küme donanım kısıtından geldi: min_boyut=512 / batch=4 ile 0,274 sn/adım ölçüldü; batch 8 denendiğinde 8,49 sn/adım'a çıktı — 8 GB VRAM yetmiyor, sürekli takas oluyor. Bölütlemede eğitim setinin tamamı kullanılabildi çünkü maskeli görüntü zaten yalnızca 1.464 tane.

Tüm deneylerde sabit tutulanlar

Parametre	Tespit	Bölütleme	Gerekçe
Model	Faster R-CNN + ResNet50-FPN	DeepLabV3 + ResNet50	tek değişken kalsın diye sabit
Epoch	6	20	süre bütçesi
Batch	4	8	8 GB VRAM sınırı
Optimizer	SGD (mom. 0,9)	SGD (mom. 0,9)	torchvision referans düzeni
Learning rate	0,005	0,01	referans değerlerin yarısı / DeepLab makalesi
Girdi boyutu	kısa kenar 512	320 kırpma (taban 384)	hız / bellek dengesi
Seed	27		her deney başında yeniden kurulur

Ölçüm: Neden Doğruluk Yetmez

Görev 4'te bu uyarı piksel doğruluğu üzerinden ölçülmüştü. Görev 5 aynı dersi **iki farklı problemde bağımsız olarak** tekrar üretmiştir — ve bu kez çok daha keskin.

$IoU = \text{kesişim} / \text{birleşim}$ · $mIoU = 21 \text{ sınıf ortalaması}$ · $mAP@0,5 = \text{PR eğrisi altındaki alan, } 20 \text{ sınıf ortalaması}$

Tespitte: sınıf doğruluğu neredeyse sabit, mAP 30 puan oynuyor

Tespitte "doğruluk" standart bir metrik değildir. Anlamli olan tek tanım şudur: *nesneyi doğru yerde bulan tahminlerin kaçının sınıfı da doğru*. Bu tanımla ölçüldüğünde:

Deney	Sınıf doğruluğu	Test mAP@0,5	Test mAP@0,75
ref_coco_egitimsiz	94,87	81,00	60,55
tespit_baseline	93,24	51,48	15,55
tespit_aug_orta	94,52	77,74	53,97
Tüm deneylerin aralığı	93,24 – 94,87	51,48 – 81,00	15,55 – 60,55

Sınıf doğruluğu 1,63 puanlık bir bantta hapis, aynı deneylerde mAP@0,5 29,52 puan oynuyor. Baseline ile referans arasında sınıf doğruluğu bakımından neredeyse hiç fark yok (%93,24 / %94,87), ama biri diğerinin skorunun üçte ikisi kadar. Sebep basit: model nesneyi *doğru yerde bulduğunda* adını da doğru koyuyor — sorun sınıflandırma değil, **nesneyi bulmak ve kutuyu oturtmak**. Yalnızca doğruluk raporlansaydı bu iki model denk görünecekti.

Bölütlemeye: piksel doğruluğu %73, mIoU %7

VOC bölütlemesinde piksellerin yaklaşık %74'ü arka plandır. Bunun sonucu bolut_scratch deneyinde uç bir örnekle görünür hale gelmiştir:

Deney	Piksel doğruluğu	mIoU	Arka plansız mIoU
bolut_scratch	73,32	6,99	3,53
bolut_baseline	90,16	56,41	54,67
bolut_aux	92,02	64,78	63,40
ref_hazir_voc	94,09	75,46	74,57

bolut_scratch piksel doğruluğunda %73,32 alıyor, mIoU'da %6,99. Model neredeyse her pikseli "arka plan" diyor; arka plan zaten piksellerin %74'ü olduğu için doğruluk yüksek görünüyor. Bu, "doğruluk yanıltıcıdır" uyarısının kitabi örneğidir: tamamen başarısız bir model, doğruluk metriğinde **çalışıyormuş gibi** görünmektedir. Görev 4'teki 4,13 / 11,47 puan farkı buna kıyasla ılımlı kalır.

Ölçüm Gürültüsü — ve Bu Raporun Kabul Ettiği Eksik

Görev 4'ün merkezinde ölçüm gürültüsü vardı: aynı konfigürasyonun üç tekrarı 0,14 / 0,95 / 2,33 puan fark vermiş, **2,33 puanlık bir eşik** belirlenmiş ve bu eşğin altındaki hiçbir fark iyileştirme sayılmamıştı.

Görev 5'te bu ölçüm yapılamamıştır. Deney tasarımı hiçbir eğitim konfigürasyonu iki kez koşulmadı — Görev 4'te gürültüyü bedavaya ölçmeyi sağlayan "aşama sınırında referans satırı tekrarlar" düzeni burada kurulmadı. Elde edilen tek tekrar ref_coco_egitimsiz'in iki koşusudur ve **o eğitim içermez**:

Tekrar	Test mAP@0,5	Test mAP@0,5:0,95	TP
ref_coco_egitimsiz — 1. koşu	81,03	54,67	2.033
ref_coco_egitimsiz — 2. koşu	81,00	54,65	2.031
Fark	0,03	0,02	2

Bu yalnızca **değerlendirme gürültüsüdür** (veri sırası + CUDA toplama sırası) ve 0,03 puandır. **Eğitim gürültüsü bundan çok daha büyüktür** — Görev 4'te aynı ayırım 0,03 değil 2,33 puandı. Dolayısıyla bu 0,03, eğitilmiş deneyleri karşılaştırmak için kullanılamaz.

Sonucu: bu raporda **birkaç puanlık farklar üstünlük kanıtı sayılmamıştır**. Ölçülmüş bir eşik olmadığı için Görev 4'teki gibi kesin bir sayı verilemiyor; bunun yerine her adımda farkın büyüklüğü açıkça yazılmış ve küçük farklarda "ölçüm karar veremedi" denmiştir. Aşağıdaki iki sonuç bu yüzden *iddia edilmemektedir*:

- Tespitte augmentation'ın katkısı: val **+0,69**, test **+0,64** puan.
- Bölütlemeye orta ile güçlü profil arasındaki fark: val **1,07** puan.

Buna karşılık aşağıdaki farklar herhangi bir makul gürültü eşliğinin **çok üstündedir** ve güvenle yorumlanabilir: transfer learning'in tespitteki katkısı (+25,83 val), bo1ut_scratch'in çöküşü (−54,30 val), sabit learning rate'in maliyeti (−19,25 val) ve eğitilmiş referansların üstünlüğü.

BÖLÜM 1 — NESNE TESPİTİ

Model: Faster R-CNN + ResNet50-FPN. İki aşamalı dedektör — önce RPN aday bölge önerir, sonra ROI başlığı her adayı sınıflandırıp kutusunu düzeltir. Tek aşamalı dedektörlerden (SSD, RetinaNet, YOLO) daha yavaş ama küçük nesnelerde daha güçlü; VOC'ta görüntü başına ortalama 2,4 nesne var ve çoğu görüntünün küçük bir bölümünü kaplıyor.

Adım 1 — Referans ve Baseline

Bu adımda iki ölçüm var ve ikisi farklı işlev görüyor:

- ref_coco_egitimsiz** — torchvision'ın COCO ağırlıklarıyla gelen Faster R-CNN. VOC görüntülerini hiç görmedi, **eğitim süresi 0**. COCO'nun 80 sınıfı VOC'un 20 sınıfına eşlendi. Ulaşılması zor bir tavan olarak konuldu.
- tespit_baseline** — yalnızca ImageNet gövdesi hazır; FPN, RPN ve ROI başlığının tamamı sıfırdan. Ölçüm sıfır noktası.


Deney	Val mAP@0,5	Test mAP@0,5	mAP@0,75	mAP@0,5:0,95	Precision	Recall	Ort. IoU	Süre
ref_coco_egitimsiz	84,36	81,00	60,55	54,65	60,07	83,72	83,35	0 sn
tespit_baseline	55,35	51,48	15,55	22,99	42,60	63,48	72,39	1.088,7 sn

Baseline'in sorunu sınıflandırma değil, yerleştirme. mAP@0,5 (gevşek eşik) farkı 29,52 puan iken mAP@0,75 (sıkı eşik) farkı **45,00 puan**. Yani baseline nesneleri kabaca doğru yerde buluyor ama kutuların kenarları tutmuyor. Ortalama IoU'nun %83,35'ten %72,39'a düşmesi aynı şeyi söylüyor.

Bu beklenen bir sonuç: baseline'da yalnızca gövde hazır, **kutu regresyonunu öğrenen kısımların hepsi (FPN, RPN, ROI) sıfırdan**. 2.000 görüntü ve 6 epoch buna yetmiyor.

Baseline hem kaçırıyor hem uyduruyor. Yanlış pozitif 2.075 (referansta 1.350), kaçırılan 886 (referansta 395). Precision %42,60 / recall %63,48 — her iki yönde de zayıf. en_iyi_epoch = 6, yani son epoch: model hâlâ yükselirken durduruldu (Görev 4 baseline'ındaki 18/20 deseniyle aynı).

tespit_baseline — Test mAP@0.5 %51.48 / mAP@0.5:0.95 %22.99
beyaz kesikli = gerçek kutu · renkli = tahmin (skor >= 0.5)



tespit_baseline — test setinden sabit örnekler. Aynı indeksler her deneyde kullanıldığı için deneyler arası görsel karşılaştırma anlamlıdır.

Adım A1 — Transfer Learning

Baseline ile referans arasındaki 29,52 puanlık açığın kaynağı belli: referans COCO'da **tespit görevi için** eğitilmiş, baseline yalnızca ImageNet sınıflandırma gövdesiyle başlıyor. Bu adımda COCO ağırlıklarıyla başlanıp VOC'ta ince ayar yapılır. Tek değişken **gövdenin kaç bloğunun eğitilebilir olduğu**.

Deney	Eğitilebilir katman	Val mAP@0,5	Test mAP@0,5	mAP@0,75	Precision	Recall	Süre
tespit_coco_ft	3	81,18	77,10	54,90	72,82	78,07	1.096,9 sn
tespit_coco_ft_katman5	5 (tamamı)	79,66	76,17	53,94	72,56	77,70	1.478,1 sn

Transfer learning bu çalışmanın en büyük tek kaldıracı: val +25,83 puan (55,35 → 81,18), test +25,62 puan (51,48 → 77,10). Görev 3'te aynı bulgu 8,30 puanı, Görev 4'te 11,61. Burada 25,83 — problem ne kadar karmaşıksa hazır ağırlığın katkısı o kadar büyük.

Gövdenin tamamını açmak zarar veriyor. katman5 val'de 1,52 puan geride ve **%35 daha yavaş** (1.478 sn / 1.097 sn). Görev 3'teki "yüksek learning rate hazır ImageNet filtrelerini ilk epoch'ta bozar" bulgusunun tespit karşılığı: ne kadar çok katman açılırsa hazır bilgiden o kadar çok kaybediliyor. Ayrıca katman5'in en iyi epoch'u 5, yani 6. epoch'ta *gerilemiş* — aşırı esnekliğin işareti.

Not: 1,52 puanlık fark ölçülmüş bir eşğin üstünde olduğu gösterilemez. Ancak süre farkı (+%35) tek başına katman5'i elemeye yeter — skor eşitken maliyet karar verir.

Adım A2 — Augmentation

A1'in kazananı (tespit_coco_ft, 3 eğitilebilir katman) sabitlenir, üzerine augmentation eklenir.

Deney	Profil	Val mAP@0,5	Test mAP@0,5	Precision	Recall	TP	FP	FN
tespit_aug_orta	çevirme + renk + ölçekleme	81,87	77,74	68,91	80,05	1.942	876	484
tespit_aug_hafif	yatay çevirme	81,30	78,11	69,21	80,05	1.942	864	484
tespit_coco_ft (A1, referans)	yok	81,18	77,10	72,82	78,07	1.894	707	532

Üç konfigürasyon 0,69 puanlık bir aralıkta (val). Ölçüm karar veremedi. Görev 4'ün eşiği (2,33) burada geçerli olsaydı bu farkların tamamı gürültü sayılırdı. Görev 5'te eşik ölçülmediği için kesin bir şey söylenemiyor, ancak **0,69 puanın bir iyileştirme kanıtı olmadığı** açıktır. tespit_aug_orta validation'a göre seçilmiştir; bu bir kural gereğidir, ölçülmüş bir üstünlük değildir.

Ortalama skor sabit kalırken hata profili değişti — asıl bulgu burada. Augmentation precision'ı düşürüp recall'ü yükseltti: %72,82 → %68,91 precision, %78,07 → %80,05 recall. Somut olarak: **48 nesne daha bulundu** (TP 1.894 → 1.942, FN 532 → 484) ama **169 yanlış pozitif eklendi** (FP 707 → 876). Model daha cesur davranıyor.


Bu, Görev 4'teki "ortalama skor loss'un ne yaptığını göstermez, hata profili gösterir" bulgusunun tespit karşılığıdır. mAP neredeyse değişmedi çünkü kazanılan recall ile kaybedilen precision birbirini götürdü.

Tespit — Nihai Sonuç

Faster R-CNN + ResNet50-FPN | COCO pretrained, 3 eğitilebilir katman
augmentation: çevirme + renk oynaması + ölçekleme | 6 epoch | 953,7 sn

Metrik	Baseline	Nihai	Kazanç	Eğitimsiz referans	Referansa fark
Test mAP@0,5	51,48	77,74	+26,26	81,00	-3,26
Test mAP@0,75	15,55	53,97	+38,42	60,55	-6,58
Test mAP@0,5:0,95	22,99	50,24	+27,25	54,65	-4,41
Precision	42,60	68,91	+26,31	60,07	+8,84
Recall	63,48	80,05	+16,57	83,72	-3,67
Sınıf doğruluğu	93,24	94,52	+1,28	94,87	-0,35

tespit_aug_orta — Test mAP@0.5 %77.74 / mAP@0.5:0.95 %50.24
beyaz kesikli = gerçek kutu · renkli = tahmin (skor >= 0.5)



tespit_aug_orta — baseline ile aynı örnekler. Kutuların hem sayısı hem oturması belirgin biçimde iyileşmiştir.

BÖLÜM 2 — SEMANTİK BÖLÜTLEME

Model: DeepLabV3 + ResNet50. Görev 4'te U-Net ailesi denenmiş ve DeepLabV3+ orada **sonuncu** olmuştu — su kütlelerinin sınırları için skip bağlantısı kritikti. VOC farklı bir problem: 21 sınıf, çok nesneli sahneler, geniş ölçek değişimi. Atrous Spatial Pyramid Pooling (ASPP) tam da bunun için tasarlandı — aynı katmanda farklı genişlemelerde konvolüsyon uygulayıp hem küçük hem büyük nesneyi aynı anda görür.

Bu rapor "DeepLabV3 VOC'ta iyidir" iddiasını doğrudan test etmemektedir. Görev 5'te tek bir bölütleme mimarisi kullanıldı; karşılaştırmalı bir mimari taraması yapılmadı. Görev 4 ile karşılaştırma yalnızca *farklı veri setlerinde farklı davranıyor* gözlemi düzeyindedir, kontrollü bir deney değildir.

VOC bölütlemesinde üç tuzak

- void (255) pikseller.** Nesne sınırlarındaki belirsiz şeritte VOC 255 etiketi kullanır. Bunlar ne arka plan ne nesne — loss'ta ve metrikte **yok sayılmalıdır** (ignore_index=255). Sayılsaydı model imkânsız bir hedefi öğrenmeye çalışır ve mIoU yapay olarak düşerdi.
- Arka plan bir sınıf.** 21 sınıfın biri arka plan ve piksellerin ~%74'ü o. mIoU'yu 21 sınıf üzerinden ortalamak literatürün standardıdır, ama arka plan dahil edildiğinde skor olduğundan iyi görünür; bu yüzden **arka plansız mIoU da ayrıca kaydedilmiştir**.
- Maske PNG'leri paletli (mode "P").** np.array(Image.open(...)) doğrudan sınıf indekslerini verir. convert("RGB") çağırmak etiketleri renklere dönüştürür ve **sessizce bozar**.

Adım 1 — Referans ve Baseline

Deney	Val mIoU	Test mIoU	Arka plansız	Piksel doğr.	Train mIoU	Overfit farkı	Süre
ref_hazir_voc	75,88	75,46	74,57	94,09	79,96	+4,08	0 sn
bolut_baseline	54,06	56,41	54,67	90,16	90,71	+36,66	890,9 sn

Görev 4'ün tam tersi bir baseline: burada ezber var, hem de çok. Train mIoU %90,71, validation %54,06 — **36,66 puanlık overfit farkı**. Görev 4'ün baseline'ında bu fark +0,15'ti (train, test'in bile *altındaydı*) ve orada augmentation hiçbir şey değiştirmemişti.

Bu ölçüm A1'in sonucunu baştan haber vermektedir: **kırılacak gerçek bir ezber var, dolayısıyla augmentation'ın kıracak bir şeyi de var**. Görev 4'te tam tersi geçerliydi.

Adım A1 — Augmentation

Deney	Profil	Val mIoU	Test mIoU	Train mIoU	Overfit farkı	Sınıf doğr.
bolut_aug_guc1u	ölçekleme + kırpma + çevirme + renk	62,00	62,20	81,11	+19,11	76,39
bolut_aug_orta	ölçekleme 0,5×–1,5× + kırpma + çevirme	60,93	62,35	81,45	+20,52	76,76
bolut_aug_hafif	yatay çevirme	55,51	58,82	87,98	+32,48	70,38
bolut_baseline (referans)	yok	54,06	56,41	90,71	+36,66	67,25

Görev 4'ün augmentation teşhisi burada doğrulanmıştır. Görev 4 raporu şunu yazmıştı: *"augmentation'ın klasik işi ezberi kırmaktır, ancak bu modelde kırılacak ezber yoktu."* Burada ezber vardı ve augmentation tam da beklediği gibi davrandı:

Overfit farkı +36,66 → +19,11 (neredeyse yarıya indi) ve **test mIoU +5,94 puan** yükseldi (56,41 → 62,35). Aynı araç, farklı hastalık, farklı sonuç. Bu, Görev 4'ün "aynı reçete farklı hastalığa uygulanınca işe yaramıyor" bulgusunun karşı yönden doğrulanmasıdır.

Augmentation'ın gücü ölçeklemede, çevirmede değil. hafif profil yalnızca yatay çevirme içerir ve baseline'a göre kazancı 2,41 puan. Ölçekleme + kırpma eklendiğinde (orta) kazanç 5,94 puana çıkıyor. VOC'ta nesneler çok farklı ölçeklerde görüldüğü için ölçek augmentasyonu doğrudan problemin kendisine dokunuyor.

Metodolojik sapma — açıkça belirtilmelidir. Validation'a göre kazanan bolut_aug_guc1u'dur (62,00 / 60,93), ancak A2 adımı orta profili sabitlenerek koşulmuştur. Aradaki fark **1,07 puandır** ve ölçülmüş bir gürültü eşiği olmadığı için anlamlı olduğu gösterilemez; ayrıca orta test'te öndedir (62,35 / 62,20) ve daha ucuzdur. Yine de **kuralın harfiyen uygulanmadığı** bir yerdir ve raporda gizlenmemiştir. Doğru davranış, ya guc1u ile devam etmek ya da gürültü eşiğini ölçüp farkın anlamsız olduğunu göstermekti.

Adım A2 — Eğitim Düzeni

Augmentation profili sabitlenir (orta); bu adımda modelin kendisi değil **nasıl eğitildiği** değişir. Üç soru sorulur.

Deney	Ne değişiyor	Val mIoU	Test mIoU	Arka plansız	Piksel doğr.	Overfit
bolut_aux	yardımcı kayıp açık (ağırlık 0,4)	66,51	64,78	63,40	92,02	+19,36
bolut_aug_orta (A1, referans)	—	60,93	62,35	60,92	90,79	+20,52
bolut_sabit_lr	poly çizelge yerine sabit lr	41,68	44,68	42,54	86,40	+25,72
bolut_scratch	hazır ağırlık yok, gövde de sıfırdan	6,63	6,99	3,53	73,32	+1,79

bolut_scratch tamamen çöktü: mIoU %6,99. Görev 4'te sıfırdan eğitilen resnet34 hiç değilse %69,94 alıyordu — burada ImageNet ağırlığı olmadan 1.464 görüntüde 21 sınıf öğrenmek imkânsız. Epoch geçmişi bunu doğruluyor: 1. epoch %3,67, 20. epoch %6,55 — model hiçbir zaman öğrenmeye başlamadı.

"Pretrained ağırlık opsiyonel değildir" bulgusunun bu çalışmadaki en sert versiyonu. Görev 2'nin "büyük model her zaman kazanmıyor", Görev 4'ün "pretrained olmadan büyük mimari dezavantaj" bulgularının uç noktası: **pretrained olmadan model hiç çalışmıyor**.

Learning rate çizelgesi bölütlemede belirleyici: –19,25 puan (val). bolut_sabit_lr yalnızca poly azaltmayı kaldırıyor ve skor 60,93'ten 41,68'e düşüyor. Epoch geçmişi neden olduğunu gösteriyor: 5. epoch'ta %35,16'ya çıkıyor, 10. epoch'ta %30,99'a *geriliyor* — sabit lr 0,01 ile SGD hiçbir zaman oturmuyor, optimum etrafında salınıyor.

Görev 3'te OneCycle / AdamW gibi düzen değişiklikleri puan ondalıklarıyla oynuyordu. Burada tek başına en büyük ikinci etki. **Eğitim düzeninin önemi probleme bağlıdır ve varsayılmaz.**


Yardımcı kayıp işe yaradı: val +5,58, test +2,43 puan. DeepLabV3'ün ara katmanına eklenen ikinci sınıflandırma başlığı (ağırlık 0,4), gradyanın ağıın derinlerine daha doğrudan ulaşmasını sağlıyor. Sınıf doğruluğu neredeyse değişmezken (76,76 → 76,71) mIoU'nun yükselmesi, kazancın **sınır kalitesinden** geldiğini gösteriyor.

Bölütleme — Nihai Sonuç

DeepLabV3 + ResNet50 | ImageNet pretrained gövde | yardımcı kayıp açık
augmentation: ölçekleme 0,5×-1,5× + kırpma + çevirme | 20 epoch | 954,8 sn

Metrik	Baseline	Nihai	Kazanç	Eğitimsiz referans	Referansa fark
Test mIoU	56,41	64,78	+8,37	75,46	-10,68
Test Dice	70,32	76,86	+6,54	85,01	-8,15
Arka plansız mIoU	54,67	63,40	+8,73	74,57	-11,17
Sınıf doğruluğu	67,25	76,71	+9,46	87,91	-11,20
Piksel doğruluğu	90,16	92,02	+1,86	94,09	-2,07
Overfit farkı	+36,66	+19,36	-17,30	+4,08	—

Son iki satır yine "doğruluk yetmez"in kanıtı. mIoU 8,37 puan yükselirken piksel doğruluğu yalnızca **1,86 puan** yükselmiştir — iyileştirmenin yaklaşık **beşte dördü** doğruluk metriğinde görünmemektedir. Görev 4'te bu oran üçte ikiydi; burada arka plan oranı daha yüksek olduğu için gizleme etkisi daha güçlü.



bolu_t_aux — nihai bölütleme modeli. Baseline görseliyle (*gorseLler/boluLeme/baseLine/*) karşılaştırıldığında sınıf karışıklıklarının ve sınır bulanıklığının azaldığı görülür.

İki Problemin Ortak Bulgusu: Eğitimsiz Referans Kazandı

Bu, Görev 5'in en önemli sonucudur ve iki bağımsız problemde de aynı yönde çıkmıştır.

Problem	Metrik	Baseline	En iyi eğitilen	Eğitimsiz referans	Referansın üstünlüğü	Referansın eğitim süresi
Tespit	mAP@0,5	51,48	77,74	81,00	+3,26	0 sn
Bölütleme	mIoU	56,41	64,78	75,46	+10,68	0 sn

Tespitte bu sonuç özellikle çarpıcıdır, çünkü orada karşılaştırma adildir. `tespit_coco_ft` zaten COCO ağırlıklarıyla *başladı* ve VOC'ta 6 epoch eğitildi. Sonuç: ağırlıklara **hiç dokunmamaktan daha kötü** (77,10 / 81,00). Yani 2.000 görüntülük bir alt kümede yapılan ince ayar, güçlü bir dedektörü iyileştirmede — **bozdu**.

Bölütlemeye karşılaştırma daha az adildir: `bolut_*` deneyleri ImageNet (yalnızca sınıflandırma) ağırlıklarıyla başlarken referans COCO+VOC *bölütleme* ağırlıklarıyla gelir. Aradaki 10,68 puanlık fark kısmen bu başlangıç avantajından kaynaklanır.

Bu bulgunun pratik anlamı. Küçük bir veri bütçesi ve kısa bir eğitim süresi varken, göreve uygun bir hazır modeli **olduğu gibi kullanmak**, onu kendi verinizde ince ayar yapmaktan daha iyi olabilir. İnce ayarın kazanç sağlaması için ya daha çok veri ya da daha dikkatli bir eğitim düzeni (düşük lr, katman dondurma, daha çok epoch) gerekir. Bu çalışma bu eşğin *nerede* olduğunu ölçmemiştir; yalnızca mevcut bütçenin altında kaldığını göstermiştir.

Yakınsama

Deney	Epoch 1	Epoch 5	Epoch 10	Son epoch	Yorum
<code>tespit_baseline</code>	9,42	54,24	—	55,35	sıfırdan başlıyor, 6 epoch yetmiyor
<code>tespit_coco_ft</code>	72,84	80,96	—	81,18	1. epoch'ta baseline'ın tavanının üstünde
<code>bolut_scratch</code>	3,67	3,94	4,41	6,55	hiç öğrenmeye başlamadı
<code>bolut_sabit_lr</code>	6,92	35,16	30,99	38,80	10. epoch'ta geriledi
<code>bolut_aux</code>	10,14	30,23	44,20	63,97	son epoch'a kadar yükseliyor

`tespit_coco_ft` 1. epoch sonunda %72,84 aldı — `tespit_baseline`'ın 6 epoch sonunda ulaştığı seviyenin (%55,35) 17 puan üstünde. Görev 4'te aynı gözlem yapılmıştı (pretrained model 1. epoch'ta sıfırdan modelin 20. epoch'una eşit). Transfer learning yalnızca tavanı değil, yakınsama hızını da değiştiriyor.

Bölütleme deneylerinin çoğu hâlâ yükselirken durduruldu. `bolut_aux`'un en iyi epoch'u 20/20, `bolut_aug_*`'ların 19/20. Epoch bütçesi bağlayıcıydı; daha uzun eğitim mutlak skorları yükseltebilir. Adımlar arası karşılaştırma bundan etkilenmez çünkü bütçe tüm deneylerde aynıdır.

Hangi Sınıflar Zor

Her iki problemde de sınıf bazlı sonuçlar kaydedilmiştir (sinif_bazli_tespit.csv, sinif_bazli_bolutleme.csv). Zorlanılan sınıflar **iki problemde de büyük ölçüde aynıdır**.

Problem	En zor 4 sınıf	En kolay 4 sınıf
Tespit (AP@0,5, nihai model)	pottedplant 48,4 · boat 52,6 · diningtable 64,2 · chair 68,2	aeroplane 90,6 · cat 90,4 · bicycle 90,0 · person 87,8
Bölütleme (IoU, nihai model)	chair 18,8 · pottedplant 36,8 · cow 39,4 · sofa 40,4	arkaplan 92,3 · bus 87,9 · aeroplane 84,1 · cat 80,9

Zorluk sınıfın kendisinden değil, geometrisinden geliyor. Her iki listede de aynı sınıflar zorlanıyor: pottedplant, chair, diningtable, sofa, boat. Ortak özellikleri:

- **İnce ve delikli yapı** (sandalye bacakları, saksı bitkisinin yaprakları) — düşük çözünürlükte kayboluyor.
- **Birbirini kapatan sahneler** (masa + sandalye + kanepe genelde aynı odada, üst üste) — sınırlar belirsiz.
- **Tanımı belirsiz sınırlar** (masanın nerede bitip sandalyenin başladığı).

chair bölütlemde %18,84 IoU ile en düşük sınıf; aynı sınıf tespitte %68,18 alıyor. **Kutuyla bulmak kolay, pikselini çizmek zor** — iki problemin zorluk profilinin nerede ayrıştığını gösteriyor.

Referansın da zorlandığı sınıflar aynı. ref_hazir_voc'ta en düşük sınıflar bicycle (38,15), chair (47,23), sofa (56,53) — yani bu zorluk modele değil **probleme** ait. Eğitimle kapatılabilecek bir açık değil.

Tüm Deneyler

Nesne tespiti

Deney	Aşama	Val mAP@0,5	Test mAP@0,5	mAP@0,75	mAP@0,5:0,95	Prec.	Recall	F1	Sınıf doğr.	Ort. IoU	Süre
ref_coco_egitimsiz	Referans	84,36	81,00	60,55	54,65	60,07	83,72	69,95	94,87	83,35	0,0
tespit_baseline	Baseline	55,35	51,48	15,55	22,99	42,60	63,48	50,98	93,24	72,39	1.088,7
tespit_coco_ft	A1 Transfer	81,18	77,10	54,90	50,01	72,82	78,07	75,35	94,20	83,00	1.096,9
tespit_coco_ft_katman5	A1 Transfer	79,66	76,17	53,94	48,92	72,56	77,70	75,04	94,65	82,49	1.478,1
tespit_aug_hafif	A2 Aug	81,30	78,11	55,03	50,28	69,21	80,05	74,24	94,80	82,76	1.083,3
tespit_aug_orta	A2 Aug	81,87	77,74	53,97	50,24	68,91	80,05	74,07	94,52	82,81	953,7

Semantik bölütleme

Deney	Aşama	Val mIoU	Test mIoU	Test Dice	Arka plansız	Piksel doğr.	Sınıf doğr.	fwIoU	Train mIoU	Overfit	Süre
ref_hazir_voc	Referans	75,88	75,46	85,01	74,57	94,09	87,91	89,68	79,96	+4,08	0,0
bolut_baseline	Baseline	54,06	56,41	70,32	54,67	90,16	67,25	83,28	90,71	+36,66	890,9
bolut_aug_hafif	A1 Aug	55,51	58,82	72,47	57,19	90,67	70,38	84,03	87,98	+32,48	891,5
bolut_aug_orta	A1 Aug	60,93	62,35	75,45	60,92	90,79	76,76	84,51	81,45	+20,52	887,5
bolut_aug_guclu	A1 Aug	62,00	62,20	75,04	60,74	90,89	76,39	84,83	81,11	+19,11	906,6
bolut_scratch	A2 Düzen	6,63	6,99	9,98	3,53	73,32	9,85	57,93	8,41	+1,79	920,4
bolut_aux	A2 Düzen	66,51	64,78	76,86	63,40	92,02	76,71	86,39	85,87	+19,36	954,8
bolut_sabit_lr	A2 Düzen	41,68	44,68	59,15	42,54	86,40	55,37	76,97	67,40	+25,72	905,0

14 deney, toplam 12.057 saniye = **201,0 dakika** GPU süresi (RTX 4060 Laptop, 8 GB) — tespit 95,0 dk, bölütleme 105,9 dk. Ham sonuçlar `sonuclar_tespit.csv` ve `sonuclar_bolutleme.csv`, sınıf bazlı sonuçlar `sinif_bazli_*.csv`, epoch geçmişleri `epoch_gecmisi_*.csv`, görseller `gorseller/{tespit,bolutleme}/{asama}/` altındadır.

Bulgular

- Her iki problemde de eğitimsiz hazır model, eğitilen en iyi modeli geçti.** Tespitte 3,26, bölütlemelerde 10,68 puan farkla — ve referansların eğitim süresi 0. Tespitte karşılaştırma adildir (ikisi de COCO ağırlıklarıyla başlar), dolayısıyla sonuç nettir: **2.000 görüntülük bir alt kümede 6 epoch ince ayar, güçlü bir dedektörü iyileştirmede, bozdu.**
- Doğruluk metriği iki problemde de yanılttı — biri uç örnek.** Tespitte sınıf doğruluğu 1,63 puanlık bir bantta kalırken mAP@0,5 29,52 puan oynadı. Bölütlemelerde boLut_scratch piksel doğruluğunda %73,32 alırken mIoU'da %6,99 aldı: tamamen başarısız bir model, doğruluk metriğinde çalışıyormuş gibi göründü.
- Görev 4'ün augmentation teşhisi karşı yönden doğrulandı.** Görev 4'te augmentation işe yaramamıştı çünkü baseline'da overfit yoktu (+0,15). Burada overfit +36,66'ydı ve augmentation onu +19,11'e indirip skoru 5,94 puan yükseltti. **Aynı araç, farklı hastalık, farklı sonuç.**
- Pretrained ağırlık opsiyonel değil — boLut_scratch hiç çalışmadı.** mIoU %6,99, 20 epoch boyunca öğrenmeye başlamadı. Görev 4'te sıfırdan resnet34 en azından %69,94 alıyordu; 1.464 görüntüde 21 sınıf için sıfırdan eğitim tamamen imkânsız.
- Transfer learning'in katkısı problem karmaşıklığıyla büyüyor.** Görev 3'te 8,30 puan, Görev 4'te 11,61, Görev 5 tespitte **25,83**. Ayrıca yakınsama hızını da değiştiriyor: `tespit_coco_ft` 1. epoch'ta baseline'in 6 epoch'luk tavanının 17 puan üstünde.
- Fazla katman açmak zarar veriyor.** Gövdenin tamamı eğitilebilir yapıldığında (katman5) val 1,52 puan düştü ve süre %35 arttı. Görev 3'ün "yüksek lr hazır filtreleri bozar" bulgusunun tespit karşılığı.
- Learning rate çizelgesi bölütlemelerde en büyük ikinci etki: -19,25 puan.** Sabit lr ile model 10. epoch'ta *geriledi*. Görev 3'te aynı tür değişiklikler puan ondalıklarıyla oynuyordu — **eğitim düzeninin önemi probleme bağlıdır ve varsayılmaz.**
- Augmentation ortalama skoru değiştirmeden hata profilini değiştirebilir.** Tespitte mAP neredeyse sabit kalırken 48 nesne daha bulundu (recall +1,98) ve 169 yanlış pozitif eklendi (precision -3,91). Ortalamaya bakan biri "hiçbir şey olmadı" derdi.
- Zorlanılan sınıflar iki problemde de aynı ve zorluk geometriden geliyor.** pottedplant, chair, diningtable, sofa, boat — ince/delikli yapı, birbirini kapatan sahneler, tanımı belirsiz sınıflar. Referans model de aynı sınıflarda zorlanıyor, yani bu açık eğitimle kapatılabilecek bir açık değil.
- Ölçüm gürültüsü ölçülmedi ve bu raporun kabul edilmiş eksiğidir.** Görev 4'te gürültü üç kez ölçülmüş, 2,33 puanlık eşik tüm sonuçları yeniden okutmuştu. Görev 5'te hiçbir eğitim konfigürasyonu tekrarlanmadı. Sonuç olarak küçük farklar (tespitte augmentation +0,69, bölütlemelerde orta/guclu 1,07) **iddia edilememektedir.**

Sınırlılıklar

- Ölçüm gürültüsü ölçülmedi.** Görev 4'ün en önemli metodolojik kazanımı burada tekrarlanmadı. Elde edilen tek tekrar eğitim içermeyen referansındır (0,03 puan) ve eğitimli deneyleri karşılaştırmak için kullanılamaz. Manşet bulgular (eğitimsiz referansın üstünlüğü, transfer learning'in +25,83'ü, boLut_scratch'in çöküşü, sabit lr'nin -19,25'i) herhangi bir makul eşğin çok üstünde olduğu için bundan etkilenmez; **adım içi küçük farklar ise yorumlanmamıştır.**
- A2 bölütleme, validation kazananiyla koşulmadı.** A1'in validation kazanani boLut_aug_guc1u (62,00) iken A2 orta profiliyle (60,93) sabitlenmiştir. Fark 1,07 puandır ve anlamlı olduğu gösterilemez, ancak kural harfiyen uygulanmamıştır.
- Tespitte eğitim seti 2.000 görüntüyle sınırlandı.** Donanım kısıtından (8 GB VRAM, batch 4). Mevcut 5.717 görüntünün yalnızca %35'i. Bu, "ince ayar referansı geçemedi" bulgusunun doğrudan sebebi olabilir — daha büyük bir bütçede sonuç değişebilir ve bu **test edilmemiştir.**
- Epoch bütçesi bağlayıcıydı.** Tespitte 6, bölütlemelerde 20 epoch. Bölütleme deneylerinin çoğunda en iyi validation skoru 19–20. epoch'ta gerçekleşti; modeller hâlâ yükselirken durduruldu.
- Tek mimari, tek seed.** Her iki problemde de tek bir model ailesi kullanıldı (Faster R-CNN, DeepLabV3); mimari karşılaştırması yapılmadı. Dolayısıyla "DeepLabV3 VOC'ta uygundur" gibi bir iddia bu çalışmayla desteklenmemektedir. Tüm deneyler seed 27 ile tek koşudur.
- Bölütlemelerde referans karşılaştırması adil değil.** Referans COCO+VOC *bölütleme* ağırlıklarıyla gelirken eğitilen modeller ImageNet *sınıflandırma* ağırlıklarıyla başlar. 10,68 puanlık farkın ne kadarının bu başlangıç avantajından geldiği ayrıştırılmamıştır. Tespitte böyle bir sorun yoktur.